



МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)


КУРСОВАЯ РАБОТА

по дисциплине

«Системы анализа больших данных»

Тема курсовой работы: «Анализ данных о дорожно транспортных происшествиях с применением технологии больших данных»

Студент группы ИНБО-20-23 Камалов Тимур Андреевич


(подпись)

Руководитель
курсовой работы

Ст. преподаватель Приходько Н.А.


(подпись)

Работа представлена к защите «__» _____ 2026 г.

Допущен к защите «__» _____ 2026 г.

Москва 2026 г.



МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)

Утверждаю
Заведующий кафедрой ПМ

Саратова Т.Е.
(подпись)

«25» февраля 2026 г.

ЗАДАНИЕ
на выполнение курсовой работы
по дисциплине «Системы анализа больших данных»

Студент Камалов Тимур Андреевич

Группа ИНБО-20-23

Тема «Анализ данных о дорожно транспортных происшествиях с применением технологии больших данных»

Исходные данные: выбранный студентом набор данных по теме работы

Перечень вопросов, подлежащих разработке, и обязательного графического материала:

Характеристика исследуемой предметной области и анализируемых данных (описание исследуемой области, актуальных задач анализа данных, применимости алгоритмов анализа данных, структуры выбранного набора данных)

Проектирование структуры хранения и конвейера обработки данных (описание архитектуры хранения и обработки данных, проектирование структуры базы данных и аналитических витрин, описание этапов получения, предобработки, преобразования и загрузки данных)

Анализ и обработка данных (описание последовательности обработки данных, расчет аналитических показателей, исследование полученной выборки, интерпретация и оценка качества полученных результатов)

Построение визуализаций и формулирование выводов (разработка графических материалов по результатам анализа, построение аналитических панелей, формулирование качественных выводов)

Срок представления к защите курсовой работы:

до «30» мая 2026 г.


Задание на курсовую работу выдал


Подпись руководителя

Приходько Н.А.
(ФИО руководителя)

«24» февраля 2026 г.

Задание на курсовую работу получил


Подпись обучающегося

Камалов Т.А.
(ФИО обучающегося)

«24» февраля 2026 г.

АННОТАЦИЯ

Курсовая работа посвящена проектированию и реализации аналитического конвейера обработки данных о дорожно-транспортных происшествиях в США на основе датасета US Accidents (2016–2023). Работа выполнена с использованием аналитической MPP-СУБД Arenadata DB (форк Greenplum) и инструмента бизнес-аналитики Apache Superset версии 6.0.0.

В работе реализована схема хранения данных «звезда»: промежуточный слой stage_accidents (7 728 394 строки), таблицы измерений dim_location и dim_weather, а также колоночная партиционированная таблица фактов fact_accident с 96 ежемесячными партициями. Выполнены аналитические запросы по штатам, погодным условиям и динамике происшествий по годам. Результаты визуализированы в пяти графиках и сводном дашборде Apache Superset.

Объём работы: 3 раздела. Количество рисунков: 12. Количество таблиц: 14. Количество листингов: 13. Количество источников: 11.

Ключевые слова: большие данные, аналитическое хранилище, схема «звезда», MPP, Arenadata DB, Greenplum, Apache Superset, дорожно-транспортные происшествия, партиционирование, распределение данных, BI-визуализация.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
1 ТЕОРЕТИЧЕСКОЕ ВВЕДЕНИЕ.....	6
1.1 Описание предметной области.....	6
1.2 Описание исходного набора данных.....	7
1.3 Описание сущностей датасета и связей между ними	8
1.4 Планируемые аналитические показатели.....	10
1.5 Выводы по первому разделу	10
2 ПРОЕКТИРОВАНИЕ АНАЛИТИЧЕСКОГО РЕШЕНИЯ.....	12
2.1 Выбор архитектуры хранения и обработки данных.....	12
2.2 Проектирование логической модели данных.....	13
2.2.1 Промежуточная таблица stage_accidents	14
2.2.2 Таблицы измерений dim_location и dim_weather.....	14
2.2.3 Таблица фактов fact_accident.....	15
2.3 Проектирование пайплайна обработки данных.....	15
2.4 Выбор технологий реализации.....	16
2.5 Проектирование аналитического слоя и витрин.....	17
2.6 Выводы по второму разделу	18
3 РЕАЛИЗАЦИЯ И ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ	19
3.1 Реализация загрузки исходных данных.....	19
3.2 Очистка и преобразование данных	20
3.3 Формирование таблиц фактов, измерений и аналитических витрин	21
3.3.1 Создание таблиц измерений и таблицы фактов.....	21
3.3.2 Наполнение таблиц измерений.....	21
3.3.3 Наполнение таблицы фактов	22
3.3.4 Проверка распределения по сегментам	23
3.3.5 Аналитические запросы.....	23
3.3.6 Сравнительный эксперимент с ключом распределения.....	26
3.4 Автоматизация пайплайна обработки данных	27

3.5 Визуализация результатов в Apache Superset.....	28
3.5.1 Развёртывание и подключение Apache Superset	28
3.5.2 Регистрация датасетов.....	29
3.5.3 Создание визуализаций	30
3.5.4 Формирование дашборда	33
3.6 Выводы по результатам реализации	33
ЗАКЛЮЧЕНИЕ.....	35
СПИСОК ИНФОРМАЦИОННЫХ ИСТОЧНИКОВ	37
ПРИЛОЖЕНИЕ А.....	38
ПРИЛОЖЕНИЕ Б	39

ВВЕДЕНИЕ

Проблема анализа дорожно-транспортных происшествий является одной из актуальных задач в области интеллектуальной обработки данных. По статистике, только на дорогах США происходит свыше шести миллионов дорожно-транспортных происшествий, что влечёт значительные человеческие и экономические потери. Аналитические системы, способные обрабатывать миллионы событий и выявлять закономерности, востребованы дорожными службами, страховыми компаниями, городскими планировщиками и системами экстренного реагирования.

Современные технологии хранения и анализа больших данных позволяют создавать масштабируемые аналитические конвейеры, способные обрабатывать терабайты данных в распределённом режиме. Массово-параллельные СУБД класса MPP, к которым относится Greenplum и его производные, обеспечивают горизонтальное масштабирование аналитических запросов за счёт параллельного выполнения на множестве узлов кластера. В сочетании с инструментами бизнес-аналитики, такими как Apache Superset, подобные решения формируют полноценный стек для анализа больших данных.

Целью курсовой работы является проектирование и реализация аналитического конвейера обработки данных о дорожно-транспортных происшествиях на основе датасета US Accidents (2016–2023) с использованием архитектуры «звезда» в Arenadata DB и визуализацией результатов в Apache Superset.

Для достижения описанной цели необходимо:

- описать предметную область и исходный набор данных;
- выделить основные сущности, аналитические показатели и вопросы;
- спроектировать архитектуру хранилища по схеме «звезда» в Arenadata DB;
- реализовать загрузку, очистку, преобразование и агрегацию данных;
- сформировать таблицы фактов, измерений и аналитические витрины;

- подключить результаты к Apache Superset и построить визуализации;
- сформулировать аналитические выводы по результатам реализации.

Объектом исследования является набор данных о дорожно-транспортных происшествиях в США за 2016–2023 годы. Предметом исследования — методы проектирования аналитического хранилища, обработки и визуализации данных для получения содержательных аналитических результатов.

В работе используются следующие технологии: Arenadata DB (Greengage Database 7.4.1, форк Greenplum), схема «звезда», колоночное хранилище ao_column с компрессией zstd, диапазонное партиционирование по дате, Apache Superset 6.0.0 через Docker Compose.

Курсовая работа состоит из трёх разделов. В первом разделе описывается предметная область, характеристики датасета, выделяются сущности и формулируются аналитические вопросы. Во втором разделе проектируется архитектура хранилища, логическая модель данных и пайплайн обработки. Третий раздел посвящён практической реализации: загрузке данных, созданию таблиц, выполнению аналитических запросов и построению визуализаций в Apache Superset.

1 ТЕОРЕТИЧЕСКОЕ ВВЕДЕНИЕ

1.1 Описание предметной области

Предметная область курсовой работы — анализ дорожно-транспортных происшествий (ДТП) на территории Соединённых Штатов Америки. Дорожно-транспортное происшествие представляет собой событие, возникающее при эксплуатации транспортного средства и сопровождающееся причинением ущерба участникам движения, имуществу или дорожной инфраструктуре. Анализ таких событий охватывает их временную и географическую локализацию, степень серьёзности последствий, влияние погодных условий и особенности дорожной обстановки.

Актуальность данной предметной области обусловлена тем, что снижение числа и серьёзности ДТП является приоритетной задачей для органов государственного управления, дорожно-транспортных ведомств и служб экстренного реагирования. Применение методов интеллектуального анализа данных позволяет выявлять географические горячие точки аварийности, определять временные паттерны, оценивать влияние погодных факторов и обосновывать принятие управленческих решений по повышению безопасности дорожного движения.

В рамках данной курсовой работы изучаются следующие аспекты предметной области. Первый аспект связан с географическим распределением ДТП: анализируется концентрация происшествий по штатам и городам США, что позволяет выявить регионы с наибольшим уровнем аварийности. Второй аспект касается влияния погодных условий: исследуется зависимость числа и серьёзности ДТП от таких факторов, как видимость, температура воздуха, осадки, скорость ветра и тип погоды. Третий аспект — временная динамика: анализируется изменение числа ДТП по годам. Четвёртый аспект связан с классификацией серьёзности последствий происшествий по шкале от 1 до 4.

Практическая значимость аналитического решения состоит в возможности применения полученных результатов для формирования программ безопасности дорожного движения, страховыми компаниями для тарификации рисков, городскими планировщиками для оптимизации дорожной инфраструктуры.

Ограничения выбранного датасета обусловлены следующими факторами: данные охватывают только 49 штатов США; часть погодных атрибутов содержит пропущенные значения (около 15% строк); данные за 2023 год охватывают только период до марта; источники данных представлены преимущественно системами мониторинга трафика, что может вносить систематическое смещение в выборку.

1.2 Описание исходного набора данных

В качестве исходного набора данных используется датасет US Accidents (2016–2023). Датасет формировался на основе нескольких источников: транспортных департаментов штатов, федерального ведомства дорожного движения, правоохранительных органов и систем мониторинга трафика в реальном времени.

Таблица 1 — Паспорт исходного набора данных

Элемент описания	Значение
Название датасета	US Accidents (2016–2023)
Источник	Kaggle / Moosavi et al. (2023)
Формат файла	CSV, разделитель — запятая, кодировка UTF-8
Объем файла	~2,9 ГБ
Количество строк	7 728 394
Количество столбцов	46
Временной диапазон	Февраль 2016 — март 2023
Единица наблюдения	Одно дорожно-транспортное происшествие
Географический охват	49 штатов США

Датасет содержит широкий перечень атрибутов, характеризующих каждое происшествие с нескольких сторон. Основные атрибуты, используемые в аналитической модели, представлены в Таблице 2.

Таблица 2 — Перечень основных атрибутов датасета

Атрибут	Роль	Тип	Описание
ID	Идентификатор	Строковый	Уникальный идентификатор ДТП
Severity	Показатель	Целочисленный	Серьёзность ДТП: от 1 (мин.) до 4 (макс.)
Start_Time	Временной	Дата/время	Дата и время начала ДТП
End_Time	Временной	Дата/время	Дата и время окончания ДТП
Distance(mi)	Показатель	Вещественный	Протяжённость последствий ДТП (мили)
City	Измерение	Текстовый	Город
County	Измерение	Текстовый	Округ
State	Измерение	Текстовый	Штат (2-символьный код)
Zipcode	Измерение	Текстовый	Почтовый индекс
Temperature(F)	Показатель	Вещественный	Температура воздуха, °F
Humidity(%)	Показатель	Вещественный	Влажность воздуха, %
Visibility(mi)	Показатель	Вещественный	Видимость, мили
Wind_Speed(mph)	Показатель	Вещественный	Скорость ветра, миль/час
Weather_Condition	Измерение	Категориальный	Тип погоды (Clear, Rain, Snow и др.)
Wind_Direction	Измерение	Категориальный	Направление ветра
Sunrise Sunset	Измерение	Категориальный	Время суток: Day / Night
Airport_Code	Измерение	Текстовый	Код ближайшего аэропорта
Timezone	Измерение	Текстовый	Часовой пояс

Анализ качества данных выявил ряд проблем, которые необходимо учитывать при построении аналитической модели. Около 15% строк содержат пропущенные значения в погодных атрибутах (Temperature, Humidity, Visibility, Wind_Speed, Weather_Condition). Поле Precipitation содержит пропуски примерно в 45% строк. Данные за 2023 год представлены только за январь–март, что занижает годовой показатель. Поле Source содержит техническую метку источника и не несёт аналитической ценности.

1.3 Описание сущностей датасета и связей между ними

При анализе структуры датасета US Accidents можно выделить три основные сущности предметной области, которые становятся основой аналитической схемы хранения данных.

Первая сущность — дорожно-транспортное происшествие — является центральной. Одна запись в датасете соответствует одному ДТП, зафиксированному в конкретный момент времени в конкретном месте. Данная сущность содержит измеряемые показатели: серьёзность происшествия (severity), протяжённость последствий на дороге (distance), а также числовые характеристики погодных условий — температуру, влажность, давление, видимость, скорость ветра и количество осадков. Гранулярность таблицы фактов: одна строка соответствует одному ДТП.

Вторая сущность — местоположение — характеризует географическую привязку происшествия. Она включает город (City), округ (County), штат (State), почтовый индекс (Zipcode), часовой пояс (Timezone) и код ближайшей метеостанции (Airport_Code). Данная сущность образует таблицу измерений dim_location. Один экземпляр может быть связан с множеством ДТП.

Третья сущность — погодные условия — агрегирует атрибуты внешней среды: тип погоды (Weather_Condition), направление ветра (Wind_Direction) и признаки освещённости (Sunrise_Sunset, Civil_Twilight, Nautical_Twilight, Astronomical_Twilight). Она образует таблицу измерений dim_weather.

Таблица 3 — Описание сущностей аналитической модели

Сущность	Смысл	Исходные поля	Связи
ДТП (факт)	Событие ДТП с числовыми показателями	ID, Severity, Start_Time, Distance, Temperature, Humidity, Visibility, Wind_Speed	Связано с одним местоположением и одними погодными условиями
Местоположение (измерение)	Географическая привязка ДТП	City, County, State, Zipcode, Timezone, Airport_Code	Одно местоположение — много ДТП
Погодные условия (измерение)	Тип погоды и условия освещённости	Weather_Condition, Wind_Direction, Sunrise_Sunset, Civil_Twilight	Одни условия — много ДТП

Связь между сущностями построена по принципу «один ко многим»: одно местоположение объединяет множество ДТП; один тип погодных условий встречается в множестве происшествий. Таблица фактов связана с таблицами измерений посредством ключей location_id и weather_id, формируемых при

наполнении измерений.

1.4 Планируемые аналитические показатели

На основании описания предметной области и структуры датасета сформулированы следующие аналитические вопросы, ответы на которые будут получены в ходе реализации конвейера.

Таблица 4 — Планируемые аналитические показатели

Показатель	Формула / способ расчёта	Измерения анализа	Ожидаемый вывод
Количество ДТП по штатам	COUNT(*) GROUP BY state	Штат	Выявление штатов с наибольшей аварийностью
Средняя серьёзность по погоде	AVG(severity) GROUP BY weather_condition	Тип погоды	Оценка влияния погоды на тяжесть последствий
Динамика ДТП по годам	COUNT(*) GROUP BY EXTRACT(YEAR FROM accident_date)	Год	Тенденции роста/снижения аварийности
Распределение по серьёзности	COUNT(*) GROUP BY severity	Уровень серьёзности (1–4)	Структура происшествий по тяжести
Число ДТП по погодным условиям	COUNT(*) GROUP BY weather_condition	Тип погоды	Погода, наиболее часто сопровождающая ДТП

1.5 Выводы по первому разделу

В первом разделе определена предметная область курсовой работы — анализ дорожно-транспортных происшествий в США — и охарактеризован исходный набор данных US Accidents, содержащий 7 728 394 записи за период 2016–2023 годов. Выделены три ключевые сущности: факт ДТП, местоположение и погодные условия, которые образуют основу аналитической

схемы «звезда». Сформулированы пять аналитических вопросов, ответы на которые будут получены в ходе реализации конвейера.

Основные ограничения датасета связаны с пропусками в погодных атрибутах, неполными данными за 2023 год и возможным систематическим смещением выборки. Указанные ограничения учитываются при очистке данных и интерпретации аналитических результатов.

2.1 Выбор архитектуры хранения и обработки данных

Для реализации аналитического решения выбрана архитектура хранения данных по схеме «звезда» (Star Schema) в массово-параллельной СУБД Arenadata DB. Схема «звезда» — одна из наиболее распространённых архитектур аналитических хранилищ данных, предложенная Ральфом Кимбаллом в рамках методологии размерного моделирования. В центре схемы располагается таблица фактов, содержащая измеряемые события или операции, а вокруг неё — денормализованные таблицы измерений, содержащие описательные атрибуты для группировки и фильтрации.

Обоснование выбора архитектуры «звезда» определяется следующими факторами. Датасет US Accidents имеет чёткую структуру с центральным потоком событий (ДТП) и повторяющимися описательными атрибутами (местоположение, погодные условия), что естественным образом соответствует модели факт–измерения. Схема «звезда» обеспечивает оптимальную производительность аналитических запросов за счёт минимального количества операций соединения (JOIN). Использование MPP-СУБД Arenadata DB позволяет распределить таблицу фактов по сегментам кластера и выполнять агрегирующие запросы параллельно. Простота схемы упрощает подключение к BI-инструменту Apache Superset.

Архитектура включает три слоя. Промежуточный слой (Staging Layer) содержит таблицу stage_accidents, в которую загружаются исходные данные из CSV-файла без преобразований. Слой хранилища (Warehouse Layer) включает таблицы измерений dim_location и dim_weather, а также таблицу фактов

fact_accident с партиционированием. Аналитический слой (Mart Layer) формируется в виде виртуальных датасетов в Apache Superset.




Рисунок 1 — Архитектурная схема аналитического решения

2.2 Проектирование логической модели данных

Логическая модель данных реализует схему «звезда» и включает четыре таблицы: одну промежуточную, одну таблицу фактов и две таблицы измерений. Структура каждой таблицы определяется исходя из анализа атрибутов датасета, требований к аналитическим запросам и особенностей хранения в Arenadata DB.

2.2.1 Промежуточная таблица `stage_accidents`

Таблица `stage_accidents` служит промежуточным слоем хранения и воспроизводит структуру исходного CSV-файла. Таблица создаётся с политикой распределения `DISTRIBUTED RANDOMLY`, что обеспечивает равномерное распределение строк по сегментам при отсутствии очевидного ключа. Тип хранения — `heap` (стандартный), так как `staging`-таблица используется преимущественно для однократной записи и последующих операций чтения при формировании измерений и фактов.

2.2.2 Таблицы измерений `dim_location` и `dim_weather`

Таблица `dim_location` содержит уникальные местоположения ДТП и включает ключ `location_id`, а также атрибуты `city`, `county`, `state`, `zipcode`, `timezone` и `airport_code`. Таблица создаётся с политикой `DISTRIBUTED REPLICATED`, при которой полная копия таблицы хранится на каждом сегменте кластера. Такой выбор обоснован сравнительно небольшим объёмом таблицы измерений (20 323 строки), что позволяет избежать операции `Redistribute Motion` при соединении с таблицей фактов.

Таблица `dim_weather` содержит уникальные комбинации погодных условий и включает ключ `weather_id`, а также атрибуты `weather_condition`, `wind_direction`, `sunrise_sunset`, `civil_twilight`, `nautical_twilight` и `astronomical_twilight`. Таблица также создаётся с политикой `DISTRIBUTED REPLICATED` — 1 681 уникальная запись занимает незначительный объём.

2.2.3 Таблица фактов fact_accident

Таблица фактов fact_accident является центральным элементом схемы. Гранулярность — одна строка соответствует одному ДТП. Таблица содержит идентификатор accident_id, дату accident_date, серьёзность severity, числовые показатели условий и внешние ключи location_id и weather_id. Таблица создаётся с типом хранения ao_column (Append-Optimized Column-Oriented) с компрессией zstd уровня 3. Данный тип хранения является оптимальным для таблиц фактов аналитических хранилищ, которые формируются однократно и в дальнейшем используются преимущественно для чтения. Таблица распределена по ключу DISTRIBUTED BY (accident_id). Партиционирование выполнено по диапазону дат с шагом один месяц — 96 партиций за период 2016–2023 годов.

Таблица 5 — Характеристики таблиц аналитической модели

Таблица	Роль	Распределение	Тип хранения	Строк
stage_accidents	Staging-слой	RANDOMLY	heap	7 728 394
dim_location	Измерение	REPLICATED	heap	20 323
dim_weather	Измерение	REPLICATED	heap	1 681
fact_accident	Факты	BY (accident_id)	ao_column + zstd	7 728 394

2.3 Проектирование пайплайна обработки данных

Пайплайн обработки данных представляет собой последовательность этапов преобразования исходного CSV-файла в аналитическую схему «звезда» и далее в визуализации в Apache Superset. Схема пайплайна: CSV-файл → stage_accidents → dim_location, dim_weather → fact_accident → витрины в Superset.

Таблица 6 — Этапы пайплайна обработки данных

Этап	Действие	Вход	Выход	Контроль
1. Загрузка	Импорт CSV через мастера Import Data	US_Accidents_March23.csv	stage_accidents	COUNT(*) = 7 728 394
2. dim_location	INSERT SELECT + GROUP BY city, state	stage_accidents	dim_location	COUNT(*) = 20 323
3. dim_weather	INSERT SELECT + GROUP BY weather_condition, wind direction	stage_accidents	dim_weather	COUNT(*) = 1 681
4. fact_accident	INSERT SELECT + LEFT JOIN с измерениями	stage_accidents + dim_*	fact_accident	COUNT(*) = 7 728 394
5. ANALYZE	Сбор статистики	fact_accident, dim_*	Обновлённая статистика	Выполнено без ошибок
6. Витрины	Виртуальные датасеты в Superset	stage_accidents	8 датасетов	5 графиков, 1 дашборд

2.4 Выбор технологий реализации

Arenadata DB (Greengage Database 7.4.1) — основная технология аналитического хранилища. Arenadata DB является корпоративным дистрибутивом Greenplum, представляющего собой массово-параллельную реляционную СУБД, основанную на PostgreSQL. Ключевые преимущества: горизонтальное масштабирование запросов между сегментами, поддержка партиционирования по диапазону дат, колоночное хранилище ao_column с компрессией zstd, политика DISTRIBUTED REPLICATED для небольших таблиц измерений, совместимость с PostgreSQL-драйвером.

Apache Superset 6.0.0 — инструмент бизнес-аналитики и визуализации данных с открытым исходным кодом. Superset предоставляет веб-интерфейс для создания интерактивных дашбордов, поддерживает подключение к Arenadata DB через стандартный PostgreSQL-драйвер, предоставляет инструменты для

создания виртуальных датасетов через SQL-запросы и поддерживает широкий набор типов визуализаций: Big Number, Bar Chart, Line Chart, Pie Chart и другие.

Docker Compose используется для развёртывания Apache Superset на узле ADCM (192.168.58.104). Контейнеризация обеспечивает изоляцию зависимостей, воспроизводимость развёртывания и упрощённое управление конфигурацией. Superset запускается вместе с зависимыми сервисами Redis (кэш) и PostgreSQL (хранение метаданных Superset).

DBeaver Community используется для загрузки исходного CSV-файла в staging-таблицу через встроенный мастер Import Data, а также для разработки и тестирования SQL-скриптов и мониторинга выполнения запросов. PsqI применяется для прямого подключения к координатору кластера при выполнении административных команд.

Ограничения: пайплайн выполняется в ручном режиме без оркестрации (Apache Airflow не используется). Данный вариант допустим для датасета объёмом ~2,9 ГБ и обеспечивает демонстрацию всех ключевых характеристик MPP-СУБД.

Таблица 7 — Роль каждой технологии в аналитическом решении

Технология	Версия	Роль в решении
Arenadata DB (Greengage)	7.4.1	Аналитическое MPP-хранилище: staging, схема «звезда», SQL-обработка
Apache Superset	6.0.0	BI-инструмент: датасеты, графики, дашборд
Docker Compose	2.x	Контейнерное развёртывание Superset
psql	PostgreSQL-совместимый	Прямое подключение к координатору кластера, выполнение административных команд
DBeaver Community	Актуальная	Загрузка CSV через мастер Import Data, разработка и тестирование SQL-скриптов
ADCM	Актуальная	Управление кластером Arenadata DB

2.5 Проектирование аналитического слоя и витрин

Аналитический слой реализован в виде виртуальных датасетов в Apache Superset, формируемых SQL-запросами к таблице stage_accidents. Данный

подход выбран потому, что виртуальные датасеты не требуют дополнительного хранения материализованных таблиц, а SQL-запросы к stage_accidents охватывают все необходимые аналитические вопросы.

Таблица 8 — Состав аналитического слоя

Датасет	Тип	Аналитический вопрос
stage_accidents	Физический	Базовый доступ ко всем данным
fact_accident	Физический	Аналитика по схеме «звезда»
dim_location	Физический	Справочник местоположений
dim_weather	Физический	Справочник погодных условий
top_states	Виртуальный	Топ-10 штатов по числу ДТП
weather_conditions	Виртуальный	Топ-10 погодных условий
accidents by year	Виртуальный	Динамика ДТП по годам
accidents by severity	Виртуальный	Распределение по серьёзности

2.6 Выводы по второму разделу

Во втором разделе спроектировано аналитическое решение, обеспечивающее обработку и анализ 7 728 394 записей о ДТП. Выбрана архитектура «звезда» в Arenadata DB как оптимальный вариант для датасета с чёткой структурой факт–измерения и объёмом ~2,9 ГБ. Логическая модель включает staging-таблицу, две REPLICATED-таблицы измерений и колоночную партиционированную таблицу фактов с 96 ежемесячными партициями. Определён шестиэтапный пайплайн. Обоснован выбор технологий: Arenadata DB для хранения и обработки, Apache Superset для визуализации, Docker Compose для развёртывания.

3 РЕАЛИЗАЦИЯ И ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ

3.1 Реализация загрузки исходных данных

Перед загрузкой данных в Arenadata DB выполнено создание отдельной схемы accidents_demo для изоляции объектов курсовой работы от системных таблиц. Затем создана staging-таблица stage_accidents, структура которой воспроизводит 46 исходных колонок CSV-файла. Скрипт создания схемы и таблицы представлен в Листинге 1.

Листинг 1 — Создание схемы и staging-таблицы (ключевой фрагмент)

```
CREATE SCHEMA accidents_demo;

CREATE TABLE accidents_demo.stage_accidents (
    id TEXT,
    severity INT,
    start_time TIMESTAMP,
    end_time TIMESTAMP,
    distance_mi NUMERIC(8,3),
    city TEXT, county TEXT, state TEXT,
    zipcode TEXT, timezone TEXT, airport_code TEXT,
    temperature_f NUMERIC(6,2), humidity_pct NUMERIC(6,2),
    pressure_in NUMERIC(6,2), visibility_mi NUMERIC(6,2),
    wind_direction TEXT, wind_speed_mph NUMERIC(6,2),
    precipitation_in NUMERIC(6,2), weather_condition TEXT,
    sunrise_sunset TEXT, civil_twilight TEXT,
    -- ... остальные поля
) DISTRIBUTED RANDOMLY;
```


Загрузка исходного CSV-файла выполнялась через мастер Import Data в DBeaver. Файл US_Accidents_March23.csv загружался в таблицу stage_accidents. При импорте были указаны следующие параметры CSV-файла: кодировка UTF-8, наличие строки заголовков, разделитель — запятая, текстовый ограничитель — двойные кавычки. После загрузки данных выполнена проверка количества строк в staging-таблице, скрипт представлен в Листинге 2.

Листинг 2 — Проверка количества загруженных строк

```
SELECT 'stage_accidents' AS table_name, COUNT(*) AS rows_cnt
FROM accidents_demo.stage_accidents;
```

Результат выполнения подтвердил успешную загрузку: таблица

stage_accidents содержит 7 728 394 строки, что совпадает с ожидаемым значением.



	A-Z table_name	123 rows_cnt
1	stage_accidents	7 728 394

Рисунок 2 — Результат проверки количества строк в stage_accidents

3.2 Очистка и преобразование данных

Загруженные данные прошли проверку качества перед формированием таблиц измерений и фактов. Правила очистки применяются не к staging-таблице — она остаётся неизменной, — а реализуются в виде условий фильтрации в SQL-запросах наполнения целевых таблиц.

Таблица 9 — Правила очистки и преобразования данных

Правило	Условие SQL	Причина применения
Исключение строк без ID	WHERE id IS NOT NULL	Без идентификатора невозможна уникальная ссылка на ДТП
Исключение строк без даты	WHERE start_time IS NOT NULL	Дата обязательна для партиционирования и временного анализа
Исключение строк без серьёзности	WHERE severity IS NOT NULL	Severity — ключевой аналитический показатель
Исключение строк без штата	WHERE state IS NOT NULL	Штат необходим для формирования dim_location
NULL в погодных полях	LEFT JOIN (допустимо)	Пропуски (~15%) сохраняются через LEFT JOIN — строки не удаляются

Строки с пропущенными значениями в погодных атрибутах (weather_condition, wind_direction) не исключаются из таблицы фактов, а получают NULL-значение по ключу weather_id через операцию LEFT JOIN. Это позволяет сохранить полный объём данных и проводить анализ ДТП без погодного контекста отдельно.

3.3 Формирование таблиц фактов, измерений и аналитических витрин

3.3.1 Создание таблиц измерений и таблицы фактов

На основе staging-таблицы сформированы таблицы измерений и таблица фактов в соответствии со спроектированной логической моделью. Полные скрипты создания таблиц вынесены в приложение Б; в данном разделе приведены ключевые фрагменты (Листинг 3).

Листинг 3 — Создание таблиц измерений и таблицы фактов

```
-- Таблица измерений dim_location
CREATE TABLE accidents_demo.dim_location (
    location_id INT, city TEXT, county TEXT,
    state TEXT, zipcode TEXT, timezone TEXT, airport_code TEXT
) DISTRIBUTED REPLICATED;

-- Таблица измерений dim_weather
CREATE TABLE accidents_demo.dim_weather (
    weather_id INT, weather_condition TEXT, wind_direction TEXT,
    sunrise_sunset TEXT, civil_twilight TEXT,
    nautical_twilight TEXT, astronomical_twilight TEXT
) DISTRIBUTED REPLICATED;

-- Таблица фактов fact_accident
CREATE TABLE accidents_demo.fact_accident (
    accident_id TEXT, accident_date DATE NOT NULL,
    severity INT NOT NULL, distance_mi NUMERIC(8,3),
    temperature_f NUMERIC(6,2), humidity_pct NUMERIC(6,2),
    pressure_in NUMERIC(6,2), visibility_mi NUMERIC(6,2),
    wind_speed_mph NUMERIC(6,2), precipitation_in NUMERIC(6,2),
    location_id INT, weather_id INT
) USING ao_column WITH (compresstype=zstd, compresslevel=3)
DISTRIBUTED BY (accident_id)
PARTITION BY RANGE (accident_date)
    START ('2016-01-01'::date) END ('2024-01-01'::date)
    EVERY ('1 month'::interval);
```

3.3.2 Наполнение таблиц измерений

В Листинге 4 представлены скрипты наполнения таблиц измерений.

Листинг 4 — Наполнение dim_location и dim_weather

```
-- dim_location (20 323 уникальных местоположения)
INSERT INTO accidents_demo.dim_location
SELECT
    ROW_NUMBER() OVER (ORDER BY state, city) AS location_id,
    city, MIN(county), state, MIN(zipcode),
    MIN(timezone), MIN(airport_code)
FROM accidents_demo.stage_accidents
WHERE state IS NOT NULL AND city IS NOT NULL
GROUP BY city, state;

-- dim_weather (1 681 уникальная запись)
INSERT INTO accidents_demo.dim_weather
SELECT
    ROW_NUMBER() OVER (ORDER BY weather_condition) AS weather_id,
    weather_condition, wind_direction,
    MIN(sunrise_sunset), MIN(civil_twilight),
    MIN(nautical_twilight), MIN(astronomical_twilight)
FROM accidents_demo.stage_accidents
WHERE weather_condition IS NOT NULL
GROUP BY weather_condition, wind_direction;
```

3.3.3 Наполнение таблицы фактов

Наполнение таблицы фактов выполнено через INSERT SELECT с LEFT JOIN к обоим измерениям. Скрипт наполнения представлен в Листинге 5.

Листинг 5 — Наполнение fact_accident через JOIN с измерениями

```
INSERT INTO accidents_demo.fact_accident
SELECT
    s.id, s.start_time::date, s.severity,
    s.distance_mi, s.temperature_f, s.humidity_pct,
    s.pressure_in, s.visibility_mi,
    s.wind_speed_mph, s.precipitation_in,
    l.location_id, w.weather_id
FROM accidents_demo.stage_accidents s
LEFT JOIN accidents_demo.dim_location l
    ON s.city = l.city AND s.state = l.state
LEFT JOIN accidents_demo.dim_weather w
    ON s.weather_condition = w.weather_condition
    AND s.wind_direction = w.wind_direction
WHERE s.id IS NOT NULL
    AND s.start_time IS NOT NULL
    AND s.severity IS NOT NULL;

-- Сбор статистики для оптимизатора
ANALYZE accidents_demo.dim_location;
ANALYZE accidents_demo.dim_weather;
ANALYZE accidents_demo.fact_accident;
```


3.3.4 Проверка распределения по сегментам

После наполнения таблицы фактов выполнена проверка равномерности распределения строк по сегментам кластера. Запрос проверки представлен в Листинге 6.

Листинг 6 — Проверка распределения по сегментам

```
SELECT gp_segment_id, COUNT(*) AS rows_cnt
FROM accidents_demo.fact_accident
GROUP BY gp_segment_id
ORDER BY gp_segment_id;
```

	123 gp_segment_id ▼	123 rows_cnt ▼
1	0	3 864 113
2	1	3 864 281

Рисунок 3 — Распределение строк fact_accident по сегментам

Результаты показывают равномерное распределение строк между двумя сегментами: незначительное отклонение в числе строк на каждом сегменте свидетельствует об эффективности хеш-распределения по ключу accident_id, обладающему высокой кардинальностью.

3.3.5 Аналитические запросы

После наполнения аналитической схемы выполнены запросы к таблице фактов и таблицам измерений для получения аналитических результатов. Запрос для анализа ДТП по штатам представлен в Листинге 7.

Листинг 7 — Анализ ДТП по штатам

```
SELECT l.state, COUNT(*) AS accidents_cnt, ROUND(AVG(f.severity)::numeric, 2)
AS avg_severity
FROM accidents_demo.fact_accident f
JOIN accidents_demo.dim_location l ON f.location_id = l.location_id
GROUP BY l.state
ORDER BY accidents_cnt DESC
LIMIT 10;
```

Результат выполнения запроса представлен в Таблице 10.

Таблица 10 — Топ-10 штатов по количеству ДТП

Штат	Количество ДТП	Средняя серьёзность
CA	1 741 422	2.17
FL	880 159	2.14
TX	582 837	2.22
SC	382 557	2.11
NY	347 932	2.26
NC	338 199	2.13
VA	303 301	2.28
PA	296 620	2.21
MN	192 079	2.16
OR	179 655	2.11

Наибольшее число зафиксированных ДТП приходится на Калифорнию (1 741 422), что примерно вдвое превышает показатель Флориды (880 159), занимающей второе место. Средняя серьёзность ДТП по всем штатам колеблется в диапазоне 2.11–2.28.

Запрос для анализа ДТП по погодным условиям представлен в Листинге 8.

Листинг 8 — Анализ ДТП по погодным условиям

```
SELECT dw.weather_condition,  
       COUNT(*) AS accidents_cnt,  
       ROUND(AVG(f.severity)::numeric, 2) AS avg_severity  
FROM accidents_demo.fact_accident f  
JOIN accidents_demo.dim_weather dw ON f.weather_id = dw.weather_id  
GROUP BY dw.weather_condition  
ORDER BY accidents_cnt DESC  
LIMIT 10;
```

Результат работы кода представлен в Таблице 11.

Таблица 11 — Топ-10 погодных условий по количеству ДТП

Погодные условия	Количество ДТП	Средняя серьёзность
Fair	2 537 082	2.13
Mostly Cloudy	1 012 868	2.22
Cloudy	811 776	2.16
Clear	808 732	2.37
Partly Cloudy	695 660	2.22
Overcast	382 863	2.39
Light Rain	351 839	2.25
Scattered Clouds	204 826	2.38
Light Snow	127 796	2.25
Fog	98 788	2.15

Наибольшее число ДТП зафиксировано в ясную погоду (Fair — 2 537 082 случаев), что объясняется большей интенсивностью движения в хорошую погоду. На втором месте — Mostly Cloudy (1 012 868 ДТП), на третьем — Cloudy (811 776 ДТП). Примечательно, что средняя серьезность ДТП при погоде Clear выше (2.37), чем при Fair (2.13), что может свидетельствовать о превышении скорости при отличной видимости. При анализе плана выполнения запроса наблюдается операция *Redistribute Motion*, возникающая при соединении таблицы фактов с *dim_weather*, так как *weather_id* не является ключом распределения таблицы фактов.

Запрос для анализа динамики ДТП по годам представлен в Листинге 9.

Листинг 9 — Динамика ДТП по годам

```
SELECT
    EXTRACT(YEAR FROM accident_date)::int AS accident_year,
    COUNT(*) AS accidents_cnt
FROM accidents_demo.fact_accident
GROUP BY 1
ORDER BY 1;
```

Результат работы кода представлен в Таблице 12.

Таблица 12 — Динамика ДТП по годам

Год	Количество ДТП
2016	410 821
2017	718 093
2018	893 426
2019	954 303
2020	1 178 913
2021	1 563 753
2022	1 762 452
2023	246 633

Данные демонстрируют устойчивый рост числа зафиксированных ДТП с 410 821 в 2016 году до 1 762 452 в 2022 году. Следует учитывать, что данный тренд отражает не только реальную динамику аварийности, но и расширение охвата систем мониторинга трафика. Резкое снижение в 2023 году (246 633) объясняется тем, что датасет охватывает только первые три месяца 2023 года.

Таблица 13 — Распределение ДТП по уровням серьёзности

Серьёзность	Количество ДТП	Доля, %
1 (минимальная)	67 366	0,9
2	6 156 981	79,7
3	1 299 337	16,8
4 (максимальная)	204 710	2,6

Подавляющее большинство ДТП — 79,7% — имеют серьёзность уровня 2, соответствующего умеренным последствиям для движения. Происшествия максимальной серьёзности (уровень 4) составляют лишь 2,6%.

3.3.6 Сравнительный эксперимент с ключом распределения

Для демонстрации влияния ключа распределения на производительность была создана альтернативная таблица `fact_accident_by_severity`, идентичная `fact_accident` по структуре, но распределённая по ключу `severity`. К обеим таблицам применялся одинаковый запрос `GROUP BY severity`, представленный в Листинге 10.

Листинг 10 — Запрос для сравнительного эксперимента

```
-- Наполнение альтернативной таблицы из fact_accident
TRUNCATE accidents_demo.fact_accident_by_severity;

INSERT INTO accidents_demo.fact_accident_by_severity
SELECT * FROM accidents_demo.fact_accident;

ANALYZE accidents_demo.fact_accident_by_severity;

-- Вариант A: DISTRIBUTED BY (accident_id)
EXPLAIN ANALYZE
SELECT severity, COUNT(*) AS accidents_cnt,
       ROUND(AVG(distance_mi)::numeric, 2) AS avg_distance
FROM accidents_demo.fact_accident
GROUP BY severity ORDER BY accidents_cnt DESC;

-- Вариант B: DISTRIBUTED BY (severity)
EXPLAIN ANALYZE
SELECT severity, COUNT(*) AS accidents_cnt,
       ROUND(AVG(distance_mi)::numeric, 2) AS avg_distance
FROM accidents_demo.fact_accident_by_severity
GROUP BY severity ORDER BY accidents_cnt DESC;
```

Результат работы кода представлен в Таблице 14.

Таблица 14 — Результаты сравнительного эксперимента

Таблица	Ключ распределения	Время выполнения, мс	Redistribute Motion
fact_accident	accident_id	5 500	Да
fact_accident_by_severity	severity	10 499	Нет

Результаты эксперимента демонстрируют неочевидный вывод. В варианте с таблицей fact_accident, распределённой по accident_id, группировка по severity требует дополнительной операции Redistribute Motion, так как ключ группировки не совпадает с ключом распределения. Время выполнения составило 5 500 мс. В варианте с fact_accident_by_severity операция Redistribute Motion отсутствует, так как группировка выполняется по тому же полю, что и ключ распределения. Однако время выполнения составило 10 499 мс — почти в 2 раза медленнее. Это объясняется тем, что при большом объёме данных (7 728 394 строк) накладные расходы на сканирование всех 96 партиций перевешивают экономию от отсутствия Redistribute Motion. Таким образом, выбор ключа распределения должен учитываться совместно с объёмом данных и характером нагрузки.

3.4 Автоматизация пайплайна обработки данных

Пайплайн обработки данных реализован в ручном режиме без применения системы оркестрации. SQL-скрипты загрузки, формирования измерений и таблицы фактов выполняются последовательно через DBeaver. Порядок выполнения строго фиксирован и воспроизводим: вначале загрузка CSV в stage_accidents через мастер Import Data, затем наполнение dim_location и dim_weather, далее наполнение fact_accident и сбор статистики, после чего создание датасетов и графиков в Superset.


Подобный подход обоснован однократным характером загрузки (датасет US Accidents не обновляется в режиме реального времени) и ограниченностью учебной инфраструктуры. В производственной системе для регулярного

обновления данных целесообразно использовать Apache Airflow для оркестрации DAG, что обеспечит воспроизводимость, мониторинг и обработку ошибок.

3.5 Визуализация результатов в Apache Superset

3.5.1 Развёртывание и подключение Apache Superset

Apache Superset версии 6.0.0 развёрнут на узле ADCM (192.168.58.104) через Docker Compose. Для развёртывания клонирован официальный репозиторий Apache Superset с GitHub, выполнен переход на тег 6.0.0 и запущены контейнеры командой `docker compose -f docker-compose-image-tag.yml up -d` (Рисунок 4).



NAME	IMAGE	COMMAND	SERVICE	CREATED
superset_app	apachesuperset.docker.scarf.sh/apache/superset:latest-dev	"/app/docker/docker-..."	superset	27 minutes ag
superset_cache	redis:7	"docker-entrypoint.s..."	redis	27 minutes ag
superset_db	postgres:16	"docker-entrypoint.s..."	db	27 minutes ag
superset_worker	apachesuperset.docker.scarf.sh/apache/superset:latest-dev	"/app/docker/docker-..."	superset-worker	27 minutes ag
superset_worker_beat	apachesuperset.docker.scarf.sh/apache/superset:latest-dev	"/app/docker/docker-..."	superset-worker-beat	27 minutes ag

Рисунок 4 — Статус контейнеров Apache Superset

После запуска все контейнеры находятся в состоянии running; контейнеры `superset_app` и `superset_worker` имеют статус healthy. Веб-интерфейс доступен по адресу `http://192.168.58.104:8088`.

Подключение Superset к кластеру Arenadata DB выполнено через тип подключения PostgreSQL с параметрами: хост 192.168.58.101 (координатор), порт 5432, база данных `adb`, пользователь `gadmin` (Рисунок 5).




Рисунок 5 — Успешное подключение Apache Superset к Arenadata DB

3.5.2 Регистрация датасетов

Для визуализации данных зарегистрированы восемь датасетов: четыре физических, соответствующих таблицам базы данных, и четыре виртуальных, формируемых SQL-запросами. Список зарегистрированных датасетов отображён на Рисунке 6.

Name	Type	Database	Schema	Owners	Last modified	Actions
accidents_by_severity	Virtual	ADB Accidents	accidents_demo	SA	22 minutes ago	
accidents_by_year	Virtual	ADB Accidents	accidents_demo	SA	25 minutes ago	
weather_conditions	Virtual	ADB Accidents	accidents_demo	SA	31 minutes ago	
stage_accidents	Physical	ADB Accidents	accidents_demo	SA	36 minutes ago	
top_states	Virtual	ADB Accidents	accidents_demo	SA	44 minutes ago	
top_states_dataset	Virtual	ADB Accidents	accidents_demo	SA	an hour ago	
dim_weather	Physical	ADB Accidents	accidents_demo	SA	an hour ago	
dim_location	Physical	ADB Accidents	accidents_demo	SA	an hour ago	
fact_accident	Physical	ADB Accidents	accidents_demo	SA	an hour ago	

Рисунок 6 — Список зарегистрированных датасетов в Apache Superset

3.5.3 Создание визуализаций

На основе зарегистрированных датасетов созданы пять графиков. Первый график — Big Number — создан на основе датасета `fact_accident`. В качестве метрики использована агрегирующая функция `COUNT(*)`. Результат — 7 728 394 ДТП (Рисунок 7).




Рисунок 7 — График «KPI: Общее количество ДТП»

Второй график — Bar Chart — создан на основе виртуального датасета `top_states`. Запрос, формирующий данный датасет, представлен в Листинге 11.

Листинг 11 — SQL-запрос виртуального датасета `top_states`

```
SELECT state, COUNT(*) AS accidents_cnt
FROM accidents_demo.stage_accidents
GROUP BY state
ORDER BY accidents_cnt DESC
LIMIT 10;
```

График отображает топ-10 штатов по количеству зафиксированных ДТП. Калифорния лидирует с показателем 1 741 422 ДТП (Рисунок 8).




Рисунок 8 — График «Топ-10 штатов по количеству ДТП»

Третий график — Bar Chart — создан на основе виртуального датасета `weather_conditions`. Наибольшее число ДТП зафиксировано в ясную погоду Fair — 2 537 082 случая (Рисунок 9).




Рисунок 9 — График «ДТП по погодным условиям»

Четвёртый график — Line Chart — создан на основе виртуального датасета `accidents_by_year`. График демонстрирует устойчивый рост числа ДТП с 2016 по 2022 год (Рисунок 10).




Рисунок 10 — График «Динамика ДТП по годам»

Пятый график — Pie Chart — создан на основе виртуального датасета accidents_by_severity. Подавляющую долю составляют ДТП с серьёзностью 2 (79,7%) (Рисунок 11).




Рисунок 11 — График «Распределение ДТП по серьёзности»

3.5.4 Формирование дашборда

На основе пяти созданных графиков сформирован аналитический дашборд «Анализ ДТП в США 2016-2023». Компоновка дашборда организована следующим образом: в верхней части расположена круговая диаграмма распределения по серьёзности КРІ с общим числом ДТП и столбчатый график ДТП по погодным условиям, а в нижней — столбчатый график ДТП по штатам, линейная диаграмма динамики ДТП по годам, а также индикатор общего количества ДТП (Рисунок 12).




Рисунок 12 — Итоговый дашборд «Анализ ДТП в США 2016-2023»

3.6 Выводы по результатам реализации

В третьем разделе реализован полный аналитический конвейер обработки данных о ДТП. Успешно загружены 7 728 394 строки из датасета US Accidents в staging-таблицу Arenadata DB. Сформированы таблицы измерений dim_location (20 323 записи) и dim_weather (1 681 запись), а также колоночная

партиционированная таблица фактов `fact_accident` с 96 ежемесячными партициями.

По результатам аналитических запросов: наибольшая концентрация ДТП зафиксирована в штате Калифорния (1 741 422 ДТП); большинство происшествий происходит в ясную погоду (Fair — 2 537 082 случаев); динамика по годам демонстрирует устойчивый рост с 2016 по 2022 год; подавляющее большинство ДТП (79,7%) относится к уровню серьёзности 2.

Сравнительный эксперимент с ключом распределения подтвердил, что `DISTRIBUTED BY (accident_id)` обеспечивает лучшую производительность агрегирующих запросов по сравнению с `DISTRIBUTED BY (severity)`, несмотря на наличие `Redistribute Motion` в первом случае.

ЗАКЛЮЧЕНИЕ

В курсовой работе выполнено проектирование и реализация аналитического конвейера обработки данных о дорожно-транспортных происшествиях в США на основе датасета US Accidents (2016–2023). Решены все семь задач, поставленных во введении.

В рамках выполнения первой и второй задач описана предметная область — анализ ДТП в США, охарактеризован датасет объёмом 7 728 394 строки, 46 атрибутов, ~2,9 ГБ, охватывающий период 2016–2023 годов. Выделены три сущности предметной области: ДТП, местоположение и погодные условия, сформулированы пять аналитических вопросов.

В рамках третьей задачи спроектирована архитектура аналитического хранилища по схеме «звезда» в Arenadata DB. Логическая модель включает staging-таблицу, две REPLICATED-таблицы измерений и партиционированную колоночную таблицу фактов с 96 ежемесячными партициями.

В ходе реализации успешно загружены данные через DBever Import Data, сформированы таблицы измерений (dim_location — 20 323, dim_weather — 1 681 записи) и таблица фактов (7 728 394 строки). Проведён сравнительный эксперимент с альтернативным ключом распределения, продемонстрировавший важность учёта кардинальности ключа при проектировании.

В рамках шестой задачи развёрнут Apache Superset 6.0.0 через Docker Compose, создано подключение к Arenadata DB, зарегистрированы восемь датасетов и построены пять визуализаций, объединённых в аналитический дашборд «Анализ ДТП в США 2016-2023».

По седьмой задаче получены следующие аналитические выводы: максимальная концентрация ДТП наблюдается в Калифорнии (1 741 422); большинство происшествий происходит в ясную погоду (2 537 082); число зафиксированных ДТП демонстрирует устойчивый рост с 2016 по 2022 год; подавляющее большинство ДТП (79,7%) относится к уровню серьёзности 2.

Ограничения реализованного решения: пайплайн выполняется в ручном режиме без оркестрации; аналитический слой формируется виртуальными датасетами к staging-таблице. Перспективы развития решения включают автоматизацию через Apache Airflow, добавление геопространственного анализа, а также машинное обучение для предсказания серьёзности ДТП по условиям.

СПИСОК ИНФОРМАЦИОННЫХ ИСТОЧНИКОВ

1. Приходько Н.А. Методические рекомендации по выполнению курсовой работы по дисциплине «Системы анализа больших данных». — М.: РТУ МИРЭА, 2026.
2. Алексеева Е.С. Методические указания к практическим работам по дисциплине «Системы анализа больших данных». — М.: РТУ МИРЭА, 2026.
3. Рогозин, М. В., Петрова, Е. А. Параллельные СУБД и технологии MPP для аналитической обработки данных // Прикладная информатика. — 2022. — № 3 (99). — С. 45–58.
4. Apache Superset Documentation [Электронный ресурс]. — Режим доступа: <https://superset.apache.org/docs/intro> — Дата обращения: 15.05.2026.
5. Arenadata DB Documentation [Электронный ресурс]. — Режим доступа: <https://docs.arenadata.io/adb/> — Дата обращения: 10.05.2026.
6. PostgreSQL 16 Documentation [Электронный ресурс]. — Режим доступа: <https://www.postgresql.org/docs/16/> — Дата обращения: 12.05.2026.
7. Kaggle. US Accidents (2016–2023) [Электронный ресурс]. — Режим доступа: <https://www.kaggle.com/datasets/sobhanmoosavi/us-accidents> — Дата обращения: 10.04.2026.
8. Greenplum Database Documentation [Электронный ресурс]. — Режим доступа: <https://docs.vmware.com/en/VMware-Greenplum/> — Дата обращения: 12.05.2026.
9. Apache Airflow Documentation [Электронный ресурс]. — Режим доступа: <https://airflow.apache.org/docs> — Дата обращения: 17.05.2026.
10. Docker Inc. Docker Compose Overview [Электронный ресурс]. — Режим доступа: <https://docs.docker.com/compose> — Дата обращения: 17.05.2026.
11. Зиновьев, А. Ю., Трубецков, А. Д. Технологии хранилищ данных в эпоху Big Data // Информационные системы и технологии. — 2022. — № 4. — С. 77–89.

ПРИЛОЖЕНИЕ А

Скрипт создания схемы и staging-таблицы (Листинг 12).

Листинг 12 — Полный скрипт создания схемы и staging-таблицы

```
CREATE SCHEMA IF NOT EXISTS accidents_demo;

CREATE TABLE accidents_demo.stage_accidents (
  id TEXT,
  source TEXT,
  severity INT,
  start_time TIMESTAMP,
  end_time TIMESTAMP,
  start_lat NUMERIC(10,6),
  start_lng NUMERIC(10,6),
  end_lat NUMERIC(10,6),
  end_lng NUMERIC(10,6),
  distance_mi NUMERIC(8,3),
  description TEXT,
  street TEXT,
  city TEXT,
  county TEXT,
  state TEXT,
  zipcode TEXT,
  country TEXT,
  timezone TEXT,
  airport_code TEXT,
  weather_timestamp TIMESTAMP,
  temperature_f NUMERIC(6,2),
  wind_chill_f NUMERIC(6,2),
  humidity_pct NUMERIC(6,2),
  pressure_in NUMERIC(6,2),
  visibility_mi NUMERIC(6,2),
  wind_direction TEXT,
  wind_speed_mph NUMERIC(6,2),
  precipitation_in NUMERIC(6,2),
  weather_condition TEXT,
  amenity BOOLEAN, bump BOOLEAN, crossing BOOLEAN,
  give_way BOOLEAN, junction BOOLEAN, no_exit BOOLEAN,
  railway BOOLEAN, roundabout BOOLEAN, station BOOLEAN,
  stop BOOLEAN, traffic_calming BOOLEAN,
  traffic_signal BOOLEAN, turning_loop BOOLEAN,
  sunrise_sunset TEXT,
  civil_twilight TEXT,
  nautical_twilight TEXT,
  astronomical_twilight TEXT
) DISTRIBUTED RANDOMLY;
```


ПРИЛОЖЕНИЕ Б

Скрипты создания таблиц фактов и измерений (Листинг 13).

Листинг 13 — Полные скрипты создания и наполнения таблиц аналитической модели

```
CREATE TABLE accidents_demo.dim_location (
    location_id INT, city TEXT, county TEXT,
    state TEXT, zipcode TEXT, timezone TEXT, airport_code TEXT
) DISTRIBUTED REPLICATED;
INSERT INTO accidents_demo.dim_location
SELECT ROW_NUMBER() OVER (ORDER BY state, city) AS location_id,
    city, MIN(county), state, MIN(zipcode),
    MIN(timezone), MIN(airport_code)
FROM accidents_demo.stage_accidents
WHERE state IS NOT NULL AND city IS NOT NULL
GROUP BY city, state;
CREATE TABLE accidents_demo.dim_weather (
    weather_id INT, weather_condition TEXT, wind_direction TEXT,
    sunrise_sunset TEXT, civil_twilight TEXT,
    nautical_twilight TEXT, astronomical_twilight TEXT
) DISTRIBUTED REPLICATED;
INSERT INTO accidents_demo.dim_weather
SELECT ROW_NUMBER() OVER (ORDER BY weather_condition) AS weather_id,
    weather_condition, wind_direction,
    MIN(sunrise_sunset), MIN(civil_twilight),
    MIN(nautical_twilight), MIN(astronomical_twilight)
FROM accidents_demo.stage_accidents
WHERE weather_condition IS NOT NULL
GROUP BY weather_condition, wind_direction;
CREATE TABLE accidents_demo.fact_accident (
    accident_id TEXT, accident_date DATE NOT NULL,
    severity INT NOT NULL, distance_mi NUMERIC(8,3),
    temperature_f NUMERIC(6,2), humidity_pct NUMERIC(6,2),
    pressure_in NUMERIC(6,2), visibility_mi NUMERIC(6,2),
    wind_speed_mph NUMERIC(6,2), precipitation_in NUMERIC(6,2),
    location_id INT, weather_id INT
) USING ao_column WITH (compressstype=zstd, compresslevel=3)
DISTRIBUTED BY (accident_id)
PARTITION BY RANGE (accident_date)
    START ('2016-01-01'::date) END ('2024-01-01'::date)
    EVERY ('1 month'::interval);
INSERT INTO accidents_demo.fact_accident
SELECT s.id, s.start_time::date, s.severity,
    s.distance_mi, s.temperature_f, s.humidity_pct,
    s.pressure_in, s.visibility_mi,
    s.wind_speed_mph, s.precipitation_in,
    l.location_id, w.weather_id
FROM accidents_demo.stage_accidents s
LEFT JOIN accidents_demo.dim_location l
    ON s.city = l.city AND s.state = l.state
LEFT JOIN accidents_demo.dim_weather w
    ON s.weather_condition = w.weather_condition
    AND s.wind_direction = w.wind_direction
WHERE s.id IS NOT NULL AND s.start_time IS NOT NULL
    AND s.severity IS NOT NULL;
ANALYZE accidents_demo.dim_location;
ANALYZE accidents_demo.dim_weather;
ANALYZE accidents_demo.fact_accident;
```